

Основы машинного обучения

Лекция 14

Градиентный бустинг. Кластеризация.

Евгений Соколов

esokolov@hse.ru

НИУ ВШЭ, 2026

Градиентный бустинг в общем виде

Задача обучения базовой модели

- Ошибка на объекте x_i при прогнозе новой модели, равном z :

$$L(y_i, a_{N-1}(x_i) + z)$$

- Посчитаем производную:

$$s_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$$

Задача обучения базовой модели

- Посчитаем производную:

$$s_i^{(N)} = -\frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$$

- Знак показывает, в какую сторону сдвигать прогноз на x_i , чтобы уменьшить ошибку композиции на нём
- Величина показывает, как сильно можно уменьшить ошибку, если сдвинуть прогноз
- Если ошибка почти не сдвинется, то нет смысла что-то менять

Градиентный бустинг

- Обучение N -й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$

$$s_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)} \text{ — сдвиги}$$

Резюме

- Чтобы учесть особенности функции потерь, можно посчитать её производные в точке текущего прогноза композиции
- Базовую модель будем обучать на эти производные (со знаком минус)

Гиперпараметры и регуляризация в бустинге

Градиентный бустинг

$$a_N(x) = a_{N-1}(x_i) + b_N(x_i)$$

- Обучение N -й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$

- $s_i^{(N)} = -\frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$ — сдвиги

Глубина деревьев

- Градиентный бустинг уменьшает смещение базовых моделей
- Разброс может увеличиться
- Поэтому в качестве базовых моделей стоит брать неглубокие деревья

Гиперпараметры

- Глубина базовых деревьев
- Число деревьев N

Проблемы бустинга

- Сдвиги показывают направление, в котором надо сдвинуть композицию на всех объектах обучающей выборки
- Базовые модели, как правило, очень простые
- Могут не справиться с приближением этого направления

Проблемы бустинга


- Сдвиги показывают направление, в котором надо сдвинуть композицию на всех объектах обучающей выборки
- Базовые модели, как правило, очень простые
- Могут не справиться с приближением этого направления
- Выход: добавлять деревья в композицию с небольшим весом

Длина шага

$$a_N(x) = a_{N-1}(x_i) + \textcolor{red}{\eta} b_N(x_i)$$

- $\eta \in (0, 1]$ — длина шага
- Можно сказать, что это регуляризация композиции
- Снижает вклад каждой модели в композицию
- Чем меньше η , тем больше надо деревьев


Длина шага



Рандомизация

- Можно обучать деревья на случайных подмножествах признаков
 - Бустинг уменьшает смещение, поэтому итоговая композиция всё равно получится качественной
 - Может снизить переобучение
-
- Можно обучать деревья на подмножествах объектов — способ борьбы с шумом в данных

Рандомизация



Гиперпараметры

- Глубина базовых деревьев
- Число деревьев N
- Длина шага
- Размер подвыборки для обучения
- и т.д.


Резюме

- Чтобы снизить переобучение, можно добавлять модели в композицию с небольшими весами
- Также может помочь обучение моделей на подвыборках

Вариации бустинга

ODT


- Oblivious decision trees
- Ограничение: на одном уровне дерева используется один и тот же предикат



<https://catboost.ai/>

Способ построения дерева


- Level-wise: дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина



<https://lightgbm.readthedocs.io/>

Способ построения дерева

- Level-wise: дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина
- Leaf-wise: среди текущих листьев выбирается тот, чьё разбиение сильнее всего уменьшает ошибку



Leaf-wise tree growth

Выбор лучшего порога для предиката

- $[x_j < t]$ — как выбрать t ?
- Вариант 1: перебрать все известные значения признака
- Вариант 2: построить гистограмму для признака и искать пороги среди границ на гистограмме
- Вариант 3: просемплировать объекты с близкими к нулю значениями производной

Регуляризация деревьев

- Базовая регуляризация: введение длины шага и семплирования признаков
- Штрафы за число листьев в дереве
- Штрафы за величину прогнозов в листьях дерева

Улучшенное обучение

- Мы обучаем деревья на сдвиги, ошибка измеряется с помощью MSE
- Когда дерево построено, можно подобрать оптимальные значения в листьях с точки зрения исходной функции потерь

Имплементации

- XGBoost
- LightGBM: leaf-wise growth, поиск порогов на основе производных
- CatBoost: ODT

Другие способы построения композиций

Что мы изучили?

- Бэггинг: усреднение «независимых» моделей
- Бустинг: последовательное обучение моделей с корректировкой

Объединение моделей

- Допустим, мы как-то обучили n моделей:

$$b_1(x), \dots, b_n(x)$$

- Сделаем их комбинацию!
- Например, сложим их с весами:

$$a(x) = \sum_{j=1}^n w_j b_j(x)$$

Объединение моделей

- Допустим, мы как-то обучили n моделей:

$$b_1(x), \dots, b_n(x)$$

- Сделаем их комбинацию!
- Например, применим «мета-модель»:


$$a(x) = c(b_1(x), \dots, b_n(x))$$

Как обучить метамодель?


$$a(x) = c(b_1(x), \dots, b_n(x))$$

- Подбирать параметры $c(\dots)$ по обучающей выборке плохо:
 - $b_j(x)$ в той или иной мере переобучаются
 - Распределение прогнозов будет разным на обучении и на тестовых данных
 - Правильно подбирать веса под поведение на тесте


Блендинг



Блендинг




Блендинг



Train

Обучаем $b_1(x), \dots, b_n(x)$



Test

обучаем мета-модель
 $a(x) = c(b_1(x), \dots, b_n(x))$

Блендинг

- Плохо, что используем не все данные
- Страдают и базовые модели, и мета-модель

Блендинг

Блок 1

Блок 2

Блок 3

обучаем $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

Блендинг

Блок 1

Блок 2

Блок 3


обучаем $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

строим прогнозы с помощью
 $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

Блендинг



$$b_1^{(1)}(x), \dots, b_n^{(1)}(x)$$



$$b_1^{(2)}(x), \dots, b_n^{(2)}(x)$$



$$b_1^{(3)}(x), \dots, b_n^{(3)}(x)$$

Блендинг

обучаем мета-модель

$$a(x) = c(b_1(x), \dots, b_n(x))$$

Блок 1

Блок 2

Блок 3

$$b_1^{(1)}(x), \dots, b_n^{(1)}(x)$$

$$b_1^{(2)}(x), \dots, b_n^{(2)}(x)$$

$$b_1^{(3)}(x), \dots, b_n^{(3)}(x)$$

Зачем это?

- Можно использовать разные классы моделей
- Эти модели могут использовать разные наборы признаков
- Важный инструмент, если боремся даже за небольшие улучшения качества

Кластеризация

На прошлых лекциях

- Методы обучения с учителем: линейные модели, решающие деревья, случайные леса, ...
- Дано: матрица «объекты-признаки» X и ответы y
- Найти: модель $a(x)$

Обучение с учителем (supervised learning)

- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning)

- Даны объекты
- Нужно найти в них внутреннюю структуру
- Примеры:
 - Кластеризация
 - Обнаружение аномалий
 - Тематическое моделирование
 - Визуализация
 - ...

Кластеризация

- Дано: матрица «объекты-признаки» X
- Найти:
 1. Множество кластеров Y
 2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров
- Каждый кластер состоит из похожих объектов
- Объекты из разных кластеров существенно отличаются

Отличия

Обучение с учителем

- Цель: минимизация функционала ошибки
- Множество ответов известно заранее
- Конкретные способы измерения качества

Кластеризация

- Нет строгой постановки
- Множество кластеров неизвестно
- Правильные ответы отсутствуют (в большинстве случаев) — нельзя измерить качество

Зачем кластеризовать?

- Маркетинг: искать похожих клиентов
 - Модерация: проверять только одно сообщение из кластера
 - Соц. опросы: выделять группы схожих анкет
 - Соц. сети: искать сообщества
-
- Выявлять типы людей и формировать поведенческие паттерны для каждого типа

Важно

- Алгоритм кластеризации не знает, чего вы хотите
- Не стоит ожидать, что при кластеризации текстов вы получите разбиение именно по темам
- Нередко кластеры оказываются неинтерпретируемыми