

Основы машинного обучения

Лекция 14

Градиентный бустинг. Кластеризация.

Евгений Соколов

esokolov@hse.ru

НИУ ВШЭ, 2026

Градиентный бустинг в общем виде

Задача обучения базовой модели

- Ошибка на объекте x_i при прогнозе новой модели, равном z :

$$L(y_i, a_{N-1}(x_i) + z)$$

- Посчитаем производную:

$$s_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$$

Задача обучения базовой модели

- Посчитаем производную:

$$s_i^{(N)} = -\frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$$

- Знак показывает, в какую сторону сдвигать прогноз на x_i , чтобы уменьшить ошибку композиции на нём
- Величина показывает, как сильно можно уменьшить ошибку, если сдвинуть прогноз
- Если ошибка почти не сдвинется, то нет смысла что-то менять

Градиентный бустинг

- Обучение N -й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$

$$s_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)} \text{ — сдвиги}$$

Резюме

- Чтобы учесть особенности функции потерь, можно посчитать её производные в точке текущего прогноза композиции
- Базовую модель будем обучать на эти производные (со знаком минус)

Гиперпараметры и регуляризация в бустинге

Градиентный бустинг

$$a_N(x) = a_{N-1}(x_i) + b_N(x_i)$$

- Обучение N -й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$

- $s_i^{(N)} = -\frac{\partial}{\partial z} L(y_i, z) \Big|_{z=a_{N-1}(x_i)}$ — сдвиги

Глубина деревьев

- Градиентный бустинг уменьшает смещение базовых моделей
- Разброс может увеличиться
- Поэтому в качестве базовых моделей стоит брать неглубокие деревья

Гиперпараметры

- Глубина базовых деревьев
- Число деревьев N

Проблемы бустинга

- Сдвиги показывают направление, в котором надо сдвинуть композицию на всех объектах обучающей выборки
- Базовые модели, как правило, очень простые
- Могут не справиться с приближением этого направления

Проблемы бустинга


- Сдвиги показывают направление, в котором надо сдвинуть композицию на всех объектах обучающей выборки
- Базовые модели, как правило, очень простые
- Могут не справиться с приближением этого направления
- Выход: добавлять деревья в композицию с небольшим весом

Длина шага

$$a_N(x) = a_{N-1}(x_i) + \eta b_N(x_i)$$

- $\eta \in (0, 1]$ — длина шага
- Можно сказать, что это регуляризация композиции
- Снижает вклад каждой модели в композицию
- Чем меньше η , тем больше надо деревьев


Длина шага



Рандомизация

- Можно обучать деревья на случайных подмножествах признаков
 - Бустинг уменьшает смещение, поэтому итоговая композиция всё равно получится качественной
 - Может снизить переобучение
-
- Можно обучать деревья на подмножествах объектов — способ борьбы с шумом в данных

Рандомизация



Гиперпараметры

- Глубина базовых деревьев
- Число деревьев N
- Длина шага
- Размер подвыборки для обучения
- и т.д.


Резюме

- Чтобы снизить переобучение, можно добавлять модели в композицию с небольшими весами
- Также может помочь обучение моделей на подвыборках

Вариации бустинга

ODT


- Oblivious decision trees
- Ограничение: на одном уровне дерева используется один и тот же предикат



<https://catboost.ai/>

Способ построения дерева


- Level-wise: дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина



<https://lightgbm.readthedocs.io/>

Способ построения дерева

- Level-wise: дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина
- Leaf-wise: среди текущих листьев выбирается тот, чьё разбиение сильнее всего уменьшает ошибку



Leaf-wise tree growth

Выбор лучшего порога для предиката

- $[x_j < t]$ — как выбрать t ?
- Вариант 1: перебрать все известные значения признака
- Вариант 2: построить гистограмму для признака и искать пороги среди границ на гистограмме
- Вариант 3: просемплировать объекты с близкими к нулю значениями производной

Регуляризация деревьев

- Базовая регуляризация: введение длины шага и семплирования признаков
- Штрафы за число листьев в дереве
- Штрафы за величину прогнозов в листьях дерева

Улучшенное обучение

- Мы обучаем деревья на сдвиги, ошибка измеряется с помощью MSE
- Когда дерево построено, можно подобрать оптимальные значения в листьях с точки зрения исходной функции потерь

Имплементации

- XGBoost
- LightGBM: leaf-wise growth, поиск порогов на основе производных
- CatBoost: ODT

Другие способы построения
композиций

Что мы изучили?

- Бэггинг: усреднение «независимых» моделей
- Бустинг: последовательное обучение моделей с корректировкой

Объединение моделей

- Допустим, мы как-то обучили n моделей:

$$b_1(x), \dots, b_n(x)$$

- Сделаем их комбинацию!
- Например, сложим их с весами:

$$a(x) = \sum_{j=1}^n w_j b_j(x)$$

Объединение моделей

- Допустим, мы как-то обучили n моделей:

$$b_1(x), \dots, b_n(x)$$

- Сделаем их комбинацию!
- Например, применим «мета-модель»:


$$a(x) = c(b_1(x), \dots, b_n(x))$$

Как обучить метамодель?


$$a(x) = c(b_1(x), \dots, b_n(x))$$

- Подбирать параметры $c(\dots)$ по обучающей выборке плохо:
 - $b_j(x)$ в той или иной мере переобучаются
 - Распределение прогнозов будет разным на обучении и на тестовых данных
 - Правильно подбирать веса под поведение на тесте


Блендинг



Блендинг




Блендинг



Train

Обучаем $b_1(x), \dots, b_n(x)$



Test

обучаем мета-модель
 $a(x) = c(b_1(x), \dots, b_n(x))$

Блендинг

- Плохо, что используем не все данные
- Страдают и базовые модели, и мета-модель

Блендинг

Блок 1

Блок 2

Блок 3

обучаем $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

Блендинг

Блок 1

Блок 2

Блок 3


обучаем $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

строим прогнозы с помощью
 $b_1^{(3)}(x), \dots, b_n^{(3)}(x)$

Блендинг



$$b_1^{(1)}(x), \dots, b_n^{(1)}(x)$$



$$b_1^{(2)}(x), \dots, b_n^{(2)}(x)$$



$$b_1^{(3)}(x), \dots, b_n^{(3)}(x)$$

Блендинг

обучаем мета-модель

$$a(x) = c(b_1(x), \dots, b_n(x))$$

Блок 1

Блок 2

Блок 3

$$b_1^{(1)}(x), \dots, b_n^{(1)}(x)$$

$$b_1^{(2)}(x), \dots, b_n^{(2)}(x)$$

$$b_1^{(3)}(x), \dots, b_n^{(3)}(x)$$

Зачем это?

- Можно использовать разные классы моделей
- Эти модели могут использовать разные наборы признаков
- Важный инструмент, если боремся даже за небольшие улучшения качества

Кластеризация

На прошлых лекциях

- Методы обучения с учителем: линейные модели, решающие деревья, случайные леса, ...
- Дано: матрица «объекты-признаки» X и ответы y
- Найти: модель $a(x)$

Обучение с учителем (supervised learning)

- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning)

- Даны объекты
- Нужно найти в них внутреннюю структуру
- Примеры:
 - Кластеризация
 - Обнаружение аномалий
 - Тематическое моделирование
 - Визуализация
 - ...

Кластеризация

- Дано: матрица «объекты-признаки» X
- Найти:
 1. Множество кластеров Y
 2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров
- Каждый кластер состоит из похожих объектов
- Объекты из разных кластеров существенно отличаются

Отличия

Обучение с учителем

- Цель: минимизация функционала ошибки
- Множество ответов известно заранее
- Конкретные способы измерения качества

Кластеризация

- Нет строгой постановки
- Множество кластеров неизвестно
- Правильные ответы отсутствуют (в большинстве случаев) — нельзя измерить качество

Зачем кластеризовать?


- Маркетинг: искать похожих клиентов
 - Модерация: проверять только одно сообщение из кластера
 - Соц. опросы: выделять группы схожих анкет
 - Соц. сети: искать сообщества
-
- Выявлять типы людей и формировать поведенческие паттерны для каждого типа

Важно

- Алгоритм кластеризации не знает, чего вы хотите
- Не стоит ожидать, что при кластеризации текстов вы получите разбиение именно по темам
- Нередко кластеры оказываются неинтерпретируемыми

Виды кластеризации


Форма кластеров




Форма кластеров




Различия в результатах работы



Исходная выборка
("Mouse" dataset)



Метод 1




Метод 2

Иерархическая кластеризация

Пример:

Кластеризация статей с Хабра



IT

Алгоритмы

Алгоритмы
и структуры
данных

Методы
машинного
обучения

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 1: в один кластер должны попадать новости на одну тему



Батыршин сыграет вместо Хабарова у «Магнитки» в матче с «Салаватом»

Место в третьей паре защиты «Магнитки» на третью встречу плей-офф Кубка Гагарина с «Салаватом Юлаевым» занял защитник Рафаэль Батыршин, сообщает из Уфы корреспондент «Чемпионата» Павел Панышев. Травмированный Ярослав Хабаров выбыл на неопределённый срок. Для форварда Оскара Осалы сезон закончен.



Футболисты ЦСКА проиграли «Долгопрудному» в товарищеском матче

Футболисты московского ЦСКА со счетом 2:3 проиграли клубу второго дивизиона "Долгопрудный" в товарищеском матче, который состоялся в Москве на стадионе "Октябрь". У армейцев забитыми мячами отличились Александр Цауня (15-я минута) и Сергей Ткачев (54).

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 2: в один кластер должны попадать новости об одном «большом» событии



Керлингистки сборной РФ сделали правильные выводы после ОИ - Сидорова
10:38 26.03.2014



Путин призвал МВД использовать в Крыму опыт работы на Олимпиаде
14:13 21.03.2014



Два "олимпийских" спецавтопарка останутся в Сочи как наследие Игр
11:50 26.03.2014

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 3: в один кластер должны попадать тексты об одной и той же новости

11:41, 08 ФЕВРАЛЯ 2014

Открытие Олимпиады в Сочи
посмотрели несколько миллиардов
человек


Олимпиада в Сочи открыта

**Церемония открытия Олимпиады в
Сочи. Онлайн-репортаж**

Требования к кластерам

- Чтобы проверить, выполняются ли требования, нужно делать разметку данных
- Для новостей: показывать ассессору пары документов и спрашивать, относятся ли они к одному кластеру

Кластеризация как основная задача





Кластеризация как вспомогательная задача

Цель: улучшение распознавания

5 5 5 5 5


«Жёсткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»




«Жесткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»



0.2



0.3



0.5

Типы задач кластеризации

- Форма кластеров, которые нужно выделять
- Плоская или древовидная структура
- Размер кластеров
- Конечная задача или вспомогательная
- Жесткая или мягкая кластеризация

K-Means

K-Means


- Дано: выборка $x_1, \dots, x_\ell$
- Параметр: число кластеров K
- Начало: случайно выбрать K центров кластеров $c_1, \dots, c_K$
- Повторять по очереди до сходимости:
 - Шаг А: отнести каждый объект к ближайшему центру
$$y_i = \arg \min_{j=1, \dots, K} \rho(x_i, c_j)$$
 - Шаг Б: переместить центр каждого кластера в центр тяжести

$$c_j = \frac{\sum_{i=1}^{\ell} x_i [y_i = j]}{\sum_{i=1}^{\ell} [y_i = j]}$$


K-Means




(a)




(b)




(c)



(d)









(e)



(f)

K-Means




Выбор числа кластеров

- Качество кластеризации: внутрикластерное расстояние



$$J(C) = \sum_{i=1}^{\ell} \rho(x_i, c_{y_i})$$

- Зависит от K
- Нужно подобрать такое K , после которого качество меняется не слишком сильно

Выбор числа кластеров



Выбор числа кластеров




Особенности K-Means

- Может работать с большими объёмами данных
- Подходит для кластеров с простой геометрией
- Требуется выбора числа кластеров

Mean Shift

Парзеновское ядро

- Обозначение: $K(z)$
- Чем ближе к нулю z , тем больше $K(z)$
- Примеры:
 - $K(z) = \exp\left(\frac{z}{h}\right)$
 - $K(z) = [z \leq h]$



Mean Shift

Пусть дан объект x

1. Вычисляем окрестность $N(x)$ — объекты, где $K(\rho(x, x_i)) > \varepsilon$
2. Находим градиент плотности:

$$m(x) = \frac{\sum_{x_i \in N(x)} x_i K(\rho(x, x_i))}{\sum_{x_i \in N(x)} K(\rho(x, x_i))} - x$$

3. Делаем шаг:


$$x \leftarrow x + m(x)$$

4. Повторяем до сходимости


Mean Shift

- Алгоритм запускается для каждого объекта
- Те объекты, для которых алгоритм сходится в общую точку, относятся к одному кластеру


Mean-Shift




Mean-Shift



Mean-Shift



Mean-Shift



Mean Shift

